

Tema 1

Estadística Descriptiva

1.1 Conceptos generales

La **Estadística** tiene por objeto el estudio de grandes cantidades de datos que son las medidas de una o varias características de los individuos de una población. Dentro de la Estadística podemos distinguir dos grandes ramas:

- **Estadística Descriptiva:** tiene por objeto ordenar los datos, agruparlos, representarlos en tablas y gráficas, y resumirlos en una serie de parámetros que permitan captar las características de la población y compararla con otras poblaciones.
- **Estadística Inferencial:** trata de establecer conclusiones generales y hacer previsiones sobre una población a partir de los datos obtenidos de una muestra.

Las características bajo estudio se dividen en:

- **Cuantitativas:** si son medibles o cuantificables (peso, altura, producción de una fábrica ...).
- **Cualitativas o atributos:** si no pueden ser medidas (profesión, estado civil, color de pelo ...).

En las características cualitativas (atributos), las distintas observaciones reciben el nombre de **modalidades**. Por ejemplo, el atributo estado civil da lugar, entre otras, a las modalidades soltero, casado y viudo.

La observación de una característica cuantitativa da lugar a distintos valores que denotaremos por $x_1, \dots, x_m$. La función X , que a cada individuo le asocia el valor correspondiente, se llama **variable estadística**.

Atendiendo a la cantidad de valores que pueden tomar, se distinguen dos tipos de variables estadísticas:

- **Variables discretas:** son aquellas que sólo pueden tomar una cantidad finita o numerable de valores (número de hijos de las familias españolas, etc.).
- **Variables continuas:** son aquellas que pueden tomar cualquier valor real dentro de un intervalo (distancia entre el 1^{er} y 2^o clasificado en una carrera de 100 metros).

Resumiendo:

$$\text{Características} \begin{cases} \text{Variables} \begin{cases} \text{Continuas} \\ \text{Discretas} \end{cases} \\ \text{Atributos} \end{cases}$$

Al conjunto de individuos objeto del estudio se le llama **población**.

Al número de individuos de la población se le llama **tamaño poblacional**.

Cuando no es posible estudiar todos los individuos de la población se estudia un subconjunto suyo que recibe el nombre de **muestra** y que, generalmente, se elige de manera aleatoria.

Al conjunto de todos los datos ordenados según un determinado criterio se le llama **serie estadística**. Se distinguen dos tipos:

- Temporales o cronológicas: surgen de la observación de un carácter en sucesivos instantes o periodos de tiempo.
- Series atemporales: surgen cuando las observaciones se realizan en un periodo de tiempo concreto.

1.1.1 Ordenación de datos

El análisis de la muestra conlleva las siguientes tareas: recogida de datos, ordenación, recuento y agrupación de datos, construcción de tablas estadísticas y representación gráfica adecuada.

De cara al análisis de la muestra, definimos:

- **Frecuencia absoluta** (n_i): es el número de veces que aparece el valor x_i en la muestra.
- **Frecuencia relativa** (f_i): es la razón entre la frecuencia absoluta del valor x_i y el tamaño de la muestra (N).

$$f_i = \frac{n_i}{N}$$

- **Frecuencia absoluta acumulada** (N_i): una vez ordenados los datos, generalmente en orden creciente, se llama así al número de veces que aparece un dato x_i y todos los anteriores. Esto es, si $x_1 < x_2 < \dots < x_i < \dots < x_m$, entonces:

$$N_i = \sum_{k=1}^i n_k$$

- **Frecuencia relativa acumulada** (F_i): es la suma de la frecuencia relativa del dato x_i y de todos los anteriores.

$$F_i = \sum_{k=1}^i f_k = \frac{N_i}{N}$$

Propiedades: dados $x_1 < x_2 < \dots < x_i < \dots < x_m$, se verifica que

- $n_i \leq N$, $1 \leq i \leq m$
- $\sum_{i=1}^m n_i = N$
- $0 \leq f_i \leq 1$, $1 \leq i \leq m$
- $\sum_{i=1}^m f_i = 1$

Cuando la variable estadística es continua o bien es discreta pero la variedad de valores observados es muy grande, esto es, se han observado muchos valores diferentes, es aconsejable agruparlos en intervalos. Cada uno de estos intervalos recibe el nombre de **intervalo de clase** y se representa mediante un número que se denomina **marca de clase**. Habitualmente, se toma como marca de clase el punto medio del intervalo.

Sin embargo, agrupar los datos produce una pérdida de información por lo que el número apropiado de intervalos dependerá del problema y del grado de precisión deseado. Como norma, tomaremos un número de intervalos igual o ligeramente superior a $\sqrt{N}$.

Ejemplos: (tablas estadísticas)

- Al lanzar un dado 10 veces se obtuvieron los siguientes resultados: 2, 6, 1, 1, 4, 3, 2, 1, 4, 5.

La variable “puntuación” es discreta. Resumimos la información de la muestra en la siguiente tabla:

x_i	n_i	N_i	f_i	F_i
1	3	3	0.3	0.3
2	2	5	0.2	0.5
3	1	6	0.1	0.6
4	2	8	0.2	0.8
5	1	9	0.1	0.9
6	1	10	0.1	1

La información recogida en la tabla nos permite afirmar que:

1. En el 30% de las tiradas se obtuvo el 1.
 2. En el 10% de las tiradas se obtuvo el 3.
 3. En el 60% de las tiradas se obtuvo el 3 o un número menor que 3.
 4. En el 20% de las tiradas se obtuvo un 5 o un 6.
- Se mide la altura en cm. de 10 personas, obteniéndose los siguientes resultados:

155, 158, 165, 167, 173, 177, 179, 181, 185, 197

En este caso lo que haremos es agrupar los datos en intervalos:


Intervalos de clase	Marcas de clase (x_i)	n_i	N_i	f_i	F_i
[154,165)	159.5	2	2	0.2	0.2
[165,176)	170.5	3	5	0.3	0.5
[176,187)	181.5	4	9	0.4	0.9
[187,198]	192.5	1	10	0.1	1

¿Qué porcentaje de personas miden al menos 187 cm.?


1.2 Representaciones gráficas

Aunque las tablas estadísticas recogen toda la información obtenida en la muestra, su traducción a un gráfico proporciona una síntesis visual de dicha información y permite una interpretación mucho más intuitiva.

- **Diagrama de barras:** es adecuado para atributos y características cuantitativas de tipo discreto. Sobre el eje OX se colocan las modalidades o los valores observados, siendo la altura de las barras proporcional a las frecuencias absolutas o relativas correspondientes.



- **Histograma:** se utiliza para variables estadísticas de tipo continuo o bien para variables discretas con un gran número de valores agrupados en intervalos. Se representan, sobre el eje OX , los extremos de los intervalos de clase y sobre ellos se construyen rectángulos con una altura tal que el área de cada uno sea proporcional a la frecuencia absoluta (o relativa) correspondiente.




Si $a_i = L_{i+1} - L_i$ denota la amplitud del intervalo i -ésimo, la altura del rectángulo correspondiente es $h_i = k \frac{n_i}{a_i}$, siendo k una constante idéntica para todos los intervalos. En el caso en que las amplitudes sean todas iguales, podemos tomar la altura de cada rectángulo igual a la frecuencia absoluta del intervalo correspondiente.

- **Polígono de frecuencias:** se forma uniendo los extremos superiores de las barras mediante una línea quebrada, en el caso de los diagramas de barras, o los puntos medios de la parte superior de los rectángulos, en el caso de los histogramas.

- **Diagrama de sectores:** son apropiados para atributos y para variables cuantitativas de tipo discreto. Se divide el círculo en sectores circulares de ángulo central proporcional a las frecuencias absolutas o relativas de los distintos atributos. De esta forma, el área de los sectores es proporcional a dichas frecuencias.

Ejemplo: se estudia el color de pelo de 100 personas, obteniéndose que 12 tienen el cabello rubio, 36 lo tienen moreno, 48 lo tienen castaño y 4 lo tienen de otro color distinto de los anteriores.

Color	Frecuencia absoluta	Angulo (en grados)
Rubio	12	43.2
Moreno	36	129.6
Castaño	48	172.8
Otro	4	14.4



Estudio del color de pelo



1.3 Características asociadas a una distribución de frecuencias

Son parámetros que sintetizan el comportamiento de una distribución.

1.3.1 Medidas de centralización

Una medida de centralización es un valor representativo de un conjunto de datos que tiende a situarse en el “centro” de estos cuando están ordenados según su magnitud. Las más comunes son la media, la moda y la mediana.

En lo que sigue supondremos que tenemos un conjunto de datos $\{x_1, \dots, x_m\}$ con frecuencias absolutas $\{n_1, \dots, n_m\}$ tales que $n_1 + \dots + n_m = N$ (tenemos en total N datos que dan lugar a m valores diferentes).

- **Media aritmética:** se representa por $\bar{X}$ y se define como

$$\bar{X} = \frac{\sum_{i=1}^m x_i n_i}{N}$$

Si la variable es continua o bien es discreta con valores agrupados en intervalos, se toma como x_i la marca de clase del intervalo i -ésimo y como n_i la frecuencia absoluta de dicho intervalo.

La media aritmética representa el centro de gravedad de la distribución aunque, si los datos están muy dispersos o hay datos dispares, su valor puede ser poco representativo.

Propiedades de la media aritmética:

1. Dada una constante k , si $z_i = x_i + k$ entonces $\bar{Z} = \bar{X} + k$.
 2. Si $z_i = kx_i$, entonces $\bar{Z} = k\bar{X}$.
 3. Si a y b son dos constantes con $b \neq 0$ y $z_i = \frac{x_i + a}{b}$, entonces $\bar{Z} = \frac{\bar{X} + a}{b}$.
 4. $\sum_{i=1}^m n_i(x_i - \bar{X}) = 0$ (la media aritmética es el centro de gravedad de los datos observados).
 5. La función $f(k) = \sum_{i=1}^m n_i(x_i - k)^2$ es mínima sí y sólo si $k = \bar{X}$.
- **Media aritmética ponderada:** a veces se asocian a los datos $x_1, \dots, x_N$ ciertos factores de peso $w_1, \dots, w_N$ que dependen de la relevancia de cada uno de ellos. En tal caso, la media se dice **ponderada** y se define como:

$$\bar{X}_p = \frac{\sum_{i=1}^N x_i w_i}{\sum_{i=1}^N w_i}$$

Ejemplo: para seleccionar personal de una empresa se han efectuado tres pruebas cuyas notas han sido x_1, x_2, x_3 . Si se quiere valorar la segunda doble que la primera y la tercera triple, la media ponderada será:

$$\bar{X}_p = \frac{x_1 + 2x_2 + 3x_3}{6}$$

- **Mediana:** una vez ordenados los datos observados, en orden creciente, la mediana es un valor que los divide en dos efectivos de igual tamaño; esto es, la mitad de los valores son menores que la mediana y la otra mitad son mayores.

A la hora de calcular la mediana de un conjunto de valores es necesario distinguir dos casos:

1. La variable no está agrupada en intervalos:

Si para un cierto valor x_i ocurre que $N_i = \frac{N}{2}$ (para ello N debe ser un número par), la mediana es

$$M_e = \frac{x_i + x_{i+1}}{2}$$

En el caso en que $N_{i-1} < \frac{N}{2} < N_i$, se tomará como mediana x_i .

Ejemplo 1: para la siguiente distribución de frecuencias

x_i	1	2	3	4	5	6
N_i	1	2	5	6	10	12

la mediana es $M_e = \frac{4+5}{2} = 4.5$

Ejemplo 2: para la distribución de frecuencias

x_i	1	2	3	4	5	6
N_i	1	3	7	12	15	18

la mediana es $M_e = 4$, puesto que $\frac{N}{2} = 9$ y $N_3 < 9 < N_4$

2. La variable está agrupada en intervalos:

Calculamos las frecuencias absolutas acumuladas (N_i), detectamos cuál es la clase mediana y finalmente, por interpolación, se determina el valor de la mediana. Esto es, si $x_i \in [L_i, L_{i+1})$ es tal que $N_{i-1} < \frac{N}{2} \leq N_i$, entonces la mediana es:

$$M_e = L_i + \frac{L_{i+1} - L_i}{n_i} \left(\frac{N}{2} - N_{i-1} \right)$$

- **Moda:** es el valor que aparece con más frecuencia en la distribución de los datos observados. Tiene sentido en caracteres cuantitativos y también en atributos. La moda no es en general única; la distribución se dice que es unimodal si presenta una única moda; bimodal si presenta dos modas; trimodal si presenta tres, etc.

En el caso de una variable no agrupada, es evidente cómo se calcula.

Cuando los datos están agrupados en intervalos de **igual amplitud**, se determina el intervalo $[L_i, L_{i+1})$ con mayor frecuencia absoluta. El valor de la moda dentro de este intervalo es:

$$M_o = L_i + \frac{L_{i+1} - L_i}{(n_i - n_{i-1}) + (n_i - n_{i+1})} (n_i - n_{i-1})$$



Cuando los datos están agrupados en intervalos de **distinta amplitud** se determina el intervalo con mayor densidad de frecuencia (frecuencia dividida por amplitud del intervalo). Si denotamos este intervalo como $[L_i, L_{i+1})$ y a su densidad de frecuencia por h_i , el valor de la moda dentro de este intervalo es:

$$M_o = L_i + \frac{L_{i+1} - L_i}{(h_i - h_{i-1}) + (h_i - h_{i+1})}(h_i - h_{i-1})$$

En el caso de que la distribución sea unimodal y simétrica, la moda, la mediana y la media aritmética coinciden.

1.3.2 Medidas de localización

Percentiles: Son valores que dividen a la muestra en cien partes con igual número de observaciones. Hay 99 percentiles que denotaremos por $P_1, P_2, \dots, P_{99}$.

1. Si la variable no está agrupada en intervalos, se define $P_t, t = 1, \dots, 99$, como:

$$P_t = \begin{cases} \frac{x_i + x_{i+1}}{2} & \text{si } N_i = \frac{t \cdot N}{100} \\ x_i & \text{si } N_{i-1} < \frac{t \cdot N}{100} < N_i \end{cases}$$

2. Si la variable está agrupada en intervalos:

Determinamos el intervalo $[L_i, L_{i+1})$ para el cual se verifica que $N_{i-1} < \frac{t \cdot N}{100} \leq N_i$. P_t será un punto de ese intervalo y viene determinado por la siguiente expresión:

$$P_t = L_i + \frac{L_{i+1} - L_i}{n_i} \left(\frac{t \cdot N}{100} - N_{i-1} \right)$$

Los percentiles P_{25}, P_{50} y P_{75} reciben el nombre de **cuartiles**. También se denotan como Q_1, Q_2 y Q_3 , respectivamente.

Los percentiles $P_{10}, P_{20}, \dots, P_{90}$ reciben el nombre de **deciles**. También se denotan como $D_1, D_2, \dots, D_9$, respectivamente.

1.3.3 Medidas de dispersión

Como su propio nombre indica, dan una idea de la dispersión de los datos.

- **Rango o recorrido:** es la diferencia entre el valor más grande y el más pequeño.
- **Varianza:**

$$S^2 = \frac{\sum_{i=1}^m (x_i - \bar{X})^2 n_i}{N}$$

- **Desviación típica:**

$$S = +\sqrt{S^2} = +\sqrt{\frac{\sum_{i=1}^m (x_i - \bar{X})^2 n_i}{N}}$$

- **Cuasivarianza:**

$$S_c^2 = \frac{\sum_{i=1}^m (x_i - \bar{X})^2 n_i}{N - 1}$$

- **Cuasidesviación típica:**

$$S_c = +\sqrt{S_c^2} = +\sqrt{\frac{\sum_{i=1}^m (x_i - \bar{X})^2 n_i}{N - 1}}$$

Propiedades:

1. $S^2 = \frac{\sum_{i=1}^m x_i^2 n_i}{N} - \bar{X}^2$
2. Si $z_i = x_i + k$, entonces $S_z^2 = S_x^2$
3. Si $z_i = kx_i$, entonces $S_z^2 = k^2 S_x^2$ y $S_z = |k| S_x$

La desviación típica y la cuasidesviación típica tienen la misma unidad que la variable bajo estudio. Si tenemos un conjunto de datos que corresponden a la altura en cm. de un grupo de personas, la desviación y la cuasidesviación típica de esos datos también se mide en cm. Sin embargo, la unidad de la varianza y la cuasivarianza es el cuadrado de la unidad en que se mide la magnitud bajo estudio. En ejemplo anterior, la varianza y cuasivarianza de las alturas se mide en cm^2 .

- **Coefficiente de variación (dispersión relativa)**

Las medidas de dispersión relativa se obtienen al dividir una medida de dispersión por una medida de centralización.

Coefficiente de variación de Pearson: se define como

$$CV = \frac{S}{|\bar{X}|} \cdot 100\%$$

No tiene sentido definirlo cuando $\bar{X} = 0$. Es un número libre de influencia por cambio de escala en las medidas, esto es, si $z_i = kx_i$, entonces $CV_z = CV_x$. En general, si el coeficiente de variación es inferior al 10% diremos que la media es representativa de la muestra; si está entre el 10% y el 30% diremos que es moderadamente representativa y si es superior al 30% diremos que es poco representativa.

Como se puede observar en la definición, el coeficiente de variación de Pearson se mide en tantos por ciento, permitiendo comparar la dispersión relativa de dos conjuntos de datos aunque las unidades de medida de esos datos sean diferentes.

1.3.4 Medidas de forma

Una vez iniciado el análisis estadístico de síntesis de información, para lo cual hemos estudiado las medidas de posición y dispersión de la distribución de una variable, necesitamos conocer más sobre su comportamiento. Las medidas de forma, como su propio nombre indica, nos proporcionan información acerca de la forma de una distribución de valores sin necesidad de llevar a cabo su representación gráfica. Se clasifican en medidas de asimetría y medidas de curtosis o apuntamiento.

Las **medidas de asimetría** tienen como finalidad proporcionar un indicador que permita establecer el grado de simetría (o asimetría) que presenta una distribución. Aunque existen distintas medidas de este tipo, destacaremos el **coeficiente de asimetría de Fisher**:


$$g_1 = \frac{1}{N} \sum_{i=1}^m n_i \left(\frac{x_i - \bar{X}}{S} \right)^3$$

Si $g_1 = 0$ la distribución es simétrica, si $g_1 > 0$ la distribución es asimétrica positiva (sesgada a la derecha), y si $g_1 < 0$ la distribución es asimétrica negativa (sesgada a la izquierda).


La distribución es asimétrica positiva cuando la suma de los cubos de las desviaciones positivas de los valores con respecto a la media es mayor que la suma de los cubos de las desviaciones con signo negativo. En caso contrario, la distribución es asimétrica negativa.

Cuando la distribución bajo estudio es campaniforme, unimodal y moderadamente asimétrica se tienen las siguientes relaciones entre la media, la moda y la mediana:


- Si es asimétrica positiva, entonces $M_o \leq M_e \leq \bar{X}$ y las frecuencias descienden más lentamente a la derecha. Son propias de las “pruebas” en las que la mayoría de los individuos puntúa bajo (por debajo de la media).
- Si es asimétrica negativa, entonces $\bar{X} \leq M_e \leq M_o$ y las frecuencias descienden más lentamente a la izquierda. Son propias de las “pruebas” en las que la mayoría de los individuos puntúa alto (por encima de la media).



Distribución sesgada a la izquierda




Distribución sesgada a la derecha



Las **medidas de curtosis** estudian la distribución de frecuencias en la zona central de la misma. La mayor o menor concentración de frecuencias alrededor de la media y en la zona central de la distribución dará lugar a una distribución más o menos apuntada. Por esta razón a las medidas de curtosis se les llama también de **apuntamiento o concentración central**. Las medidas de curtosis se aplican a **distribuciones campaniformes**, es decir, unimodales simétricas o con ligera asimetría. Para estudiar la curtosis de una distribución es necesario definir previamente una distribución tipo, que vamos a tomar como modelo de referencia. Esta distribución es la **Normal**, que corresponde a fenómenos muy corrientes en la naturaleza, y cuya representación gráfica es la campana de Gauss.

Tomando la distribución Normal como referencia, diremos que una distribución puede ser más apuntada que la normal (*leptocúrtica*) o menos apuntada (*platicúrtica*). A la distribución Normal, desde el punto de vista de la curtosis, se le llama *mesocúrtica*. Con la curtosis se estudia la deformación, en sentido vertical, respecto a la Normal, de una distribución.



Al igual que en el caso de las medidas de asimetría, si bien existen numerosas medidas de curtosis, destacaremos aquí el **coeficiente de Curtosis**:

$$g_2 = \frac{\sum_{i=1}^m \left(\frac{x_i - \bar{X}}{S} \right)^4 n_i}{N} - 3$$

Una distribución es mesocúrtica cuando $g_2 = 0$, leptocúrtica si $g_2 > 0$ y platicúrtica si $g_2 < 0$.

1.4 Series estadísticas de dos caracteres

1.4.1 Conceptos generales

Las series estadísticas de dos caracteres resultan de la observación conjunta de dos características en los individuos de una población o muestra. Así, si tenemos una muestra de tamaño N y observamos las características X e Y , cada observación determinará una pareja de valores (x, y) . Si las observaciones de X dan lugar a $x_1, x_2, \dots, x_n$ valores distintos y los de Y a $y_1, y_2, \dots, y_m$, cada observación vendrá descrita por una pareja de valores (x_i, y_j) . Denotaremos por n_{ij} a la **frecuencia absoluta conjunta** del dato (x_i, y_j) .

1.4.2 Ordenación y representación de los datos

Como cada uno de los valores de una de las variables suele aparecer con distintos valores de la otra, los datos se ordenan en una **tabla de doble entrada** como la que sigue:

$X \setminus Y$	y_1	y_2	$\dots$	y_j	$\dots$	y_m
x_1	n_{11}	n_{12}	$\dots$	n_{1j}	$\dots$	n_{1m}
x_2	n_{21}	n_{22}	$\dots$	n_{2j}	$\dots$	n_{2m}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	n_{i1}	n_{i2}	$\dots$	n_{ij}	$\dots$	n_{im}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_n	n_{n1}	n_{n2}	$\dots$	n_{nj}	$\dots$	n_{nm}

Si los datos se dan agrupados en intervalos, x_i e y_j representan las marcas de clases respectivas.

Se utiliza también, aunque es menos habitual, otro tipo de tabla que consiste en presentar los datos en dos columnas, una para X y otra para Y y en una tercera columna las frecuencias conjuntas.


X	Y	n_{ij}
x_1	y_1	n_{11}
x_1	y_2	n_{12}
$\vdots$	$\vdots$	$\vdots$
x_1	y_m	n_{1m}
x_2	y_1	n_{21}
$\vdots$	$\vdots$	$\vdots$

Se define la **frecuencia relativa conjunta** de (x_i, y_j) como $f_{ij} = \frac{n_{ij}}{N}$.

Se verifica que

$$\sum_{i=1}^n \sum_{j=1}^m n_{ij} = N \quad \text{y} \quad \sum_{i=1}^n \sum_{j=1}^m f_{ij} = \frac{1}{N} \cdot \sum_{i=1}^n \sum_{j=1}^m n_{ij} = 1$$

Para variables bidimensionales los diagramas de barras se construirán situando sobre el plano XY los valores (x_i, y_j) y sobre cada uno de ellos se levanta una barra de altura proporcional a la frecuencia n_{ij} .



Si sobre el plano XY se dibujan los puntos de coordenadas (x_i, y_j) , se obtiene una **nube de puntos**, llamada también **diagrama de dispersión**, que dará idea de la posible dependencia entre ambas variables.

Ejemplo de tabla de doble entrada: El departamento de personal de una empresa encargó un estudio para conocer la posible relación existente entre la edad y el absentismo laboral de los trabajadores. Los datos obtenidos se reflejan en la siguiente tabla:

Edad \ Absentismo	[0, 5)	[5, 10)	[10, 15)	[15, 20)
[15, 25)	—	3	7	1
[25, 35)	—	6	2	—
[35, 45)	1	3	2	—
[45, 55)	2	5	1	—
[55, 65)	3	2	—	1

1.4.3 Distribuciones marginales

Podemos estar interesados en una de las características independientemente del valor que tome la otra. En el ejemplo anterior podríamos estar interesados en estudiar el absentismo laboral sin tener en cuenta las edades.

Si a una tabla de doble entrada añadimos una nueva fila y una nueva columna que recojan las sumas parciales de cada columna y fila, respectivamente, tendremos en la nueva fila las frecuencias absolutas de los valores de Y y en la nueva columna las frecuencias de los valores de X . La nueva columna contiene lo que se conoce con el nombre de **distribución marginal** de X . La nueva fila contiene la **distribución marginal** de Y .

$X \setminus Y$	y_1	y_2	$\cdots$	y_j	$\cdots$	y_m	
x_1	n_{11}	n_{12}	$\cdots$	n_{1j}	$\cdots$	n_{1m}	$n_{1\cdot}$
x_2	n_{21}	n_{22}	$\cdots$	n_{2j}	$\cdots$	n_{2m}	$n_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	n_{i1}	n_{i2}	$\cdots$	n_{ij}	$\cdots$	n_{im}	$n_{i\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_n	n_{n1}	n_{n2}	$\cdots$	n_{nj}	$\cdots$	n_{nm}	$n_{n\cdot}$
	$n_{\cdot 1}$	$n_{\cdot 2}$	$\cdots$	$n_{\cdot j}$	$\cdots$	$n_{\cdot m}$	$n_{\cdot \cdot}$

Donde hemos llamado

$$n_{i\cdot} = \sum_{j=1}^m n_{ij} \quad \text{a la frecuencia marginal de } x_i$$

$$n_{\cdot j} = \sum_{i=1}^n n_{ij} \quad \text{a la frecuencia marginal de } y_j$$

$$n_{\cdot \cdot} = \sum_{i=1}^n n_{i\cdot} = \sum_{j=1}^m n_{\cdot j} = \sum_{i=1}^n \sum_{j=1}^m n_{ij} = N$$

Las frecuencias relativas marginales se definen como

$$f_{i\cdot} = \frac{n_{i\cdot}}{N} \quad \text{y} \quad f_{\cdot j} = \frac{n_{\cdot j}}{N}$$

Es fácil observar que

$$\sum_{i=1}^n f_{i\cdot} = \sum_{j=1}^m f_{\cdot j} = 1$$

Siguiendo con el ejemplo anterior, la tabla resultante sería:

Edad \ Absentismo	[0, 5)	[5, 10)	[10, 15)	[15, 20)	
[15, 25)	—	3	7	1	11
[25, 35)	—	6	2	—	8
[35, 45)	1	3	2	—	6
[45, 55)	2	5	1	—	8
[55, 65)	3	2	—	1	6
	6	19	12	2	39

La nueva columna contiene la distribución de las edades de los trabajadores y la nueva fila la distribución del absentismo laboral. Hacer un estudio de cada una de ellas.

1.4.4 Distribuciones condicionadas

En el ejemplo anterior podríamos estar interesados en estudiar el absentismo laboral para el grupo de trabajadores de edades comprendidas entre 35 y 45 años, o la distribución por edades para el grupo de trabajadores que han faltado entre 10 y 15 días. Generalizando las ideas apuntadas, supongamos que tenemos interés en estudiar la distribución de X para un cierto valor y_j de la variable Y .

Consideremos la columna de y_j , es decir, tomamos una submuestra de $n_{\cdot j}$ individuos.

$Y = y_j$		
X	frec. absoluta	frec. relativa
x_1	n_{1j}	f_{1j}^j
x_2	n_{2j}	f_{2j}^j
$\vdots$	$\vdots$	$\vdots$
x_i	n_{ij}	f_{ij}^j
$\vdots$	$\vdots$	$\vdots$
x_n	n_{nj}	f_{nj}^j
	$\sum_{j=1}^m n_{ij} = n_{\cdot j}$	

$f_{ij}^j = \frac{n_{ij}}{n_{\cdot j}}$ representa la frecuencia relativa de x_i condicionada por y_j , es decir, la proporción de veces en que aparece (x_i, y_j) de entre el total de veces en que aparece y_j .

La tabla anterior representa pues la **distribución de X condicionada** por y_j , se denota por $X|_{y_j}$ ó por $X|_{Y=y_j}$.

Análogamente se define la distribución de Y condicionada por x_i .

Se verifica que

$$f_{ij} = \frac{n_{ij}}{N} = \frac{n_{ij}}{n_{.j}} \cdot \frac{n_{.j}}{N} = f_i^j \cdot f_{.j} \quad (1.1)$$

y del mismo modo

$$f_{ij} = f_j^i \cdot f_i.$$

es decir, la **frecuencia relativa conjunta** es igual al producto de la **frecuencia relativa condicional** por la **frecuencia relativa marginal**.

Siguiendo con el ejemplo anterior, la tabla que sigue es la distribución de $X|_{Y \in [10, 15)}$, esto es, la distribución de edades de los trabajadores con absentismo entre 10 y 15 días.

$Y \in [10, 15)$		
X=edad	frec. absoluta	frec. relativa
[15, 25)	7	7/12
[25, 35)	2	2/12
[35, 45)	2	2/12
[45, 55)	1	1/12
[55, 65)	0	0
	12	

1.4.5 Independencia

Definición 1.4.1.— Se dice que el carácter X es independiente del carácter Y (la variable X es independiente de Y) si las distribuciones de X condicionadas por cada y_j son iguales, es decir, si $X|_{y_j}$ no depende de y_j .

La definición anterior equivale a exigir que las columnas de las frecuencias relativas de las distribuciones condicionadas por cada y_j sean iguales y por tanto que las columnas de las frecuencias absolutas sean proporcionales.

Proposición 1.4.2.— Si X es independiente de Y , entonces las frecuencias relativas condicionadas de X coinciden con las frecuencias relativas marginales de X , es decir, $f_i^j = f_i \quad \forall j = 1, \dots, m \quad \forall i = 1, \dots, n$.

Proposición 1.4.3.— Si X es independiente de Y entonces Y es independiente de X .

Proposición 1.4.4.— X e Y son independientes si y sólo si $f_{ij} = f_i \cdot f_{.j}$, o lo que es igual, $n_{ij} = \frac{n_{i.} \cdot n_{.j}}{N}$

Ejemplo: El estudio de cierto tipo de averías, en una muestra de coches de dos marcas distintas, dió el resultado que se recoge en la siguiente tabla:

	Marca 1	Marca 2	Totales
Avería	200	150	350
No avería	150	180	330
Totales	350	330	680

Estudiar, a partir de los datos, si la avería es independiente de la marca.

1.4.6 Covarianza

La **covarianza** se define como la media del producto de las desviaciones de X respecto de su media por las desviaciones de Y respecto de la suya. Se representa por S_{XY} .

$$S_{XY} = \frac{\sum_{i=1}^n \sum_{j=1}^m (x_i - \bar{X}) \cdot (y_j - \bar{Y}) \cdot n_{ij}}{N}$$

Una covarianza positiva indica relación directa entre las variables (valores grandes de una variable están asociados con valores grandes de la otra). Una covarianza negativa indica relación inversa entre las variables (valores grandes de una variable están asociados con valores pequeños de la otra). Alternativamente, la covarianza puede calcularse como

$$S_{XY} = \frac{\sum_{i=1}^n \sum_{j=1}^m x_i \cdot y_j \cdot n_{ij}}{N} - \bar{X} \cdot \bar{Y}$$

Propiedades de la covarianza

1. La covarianza es invariante por cambios de origen. Es decir, si hacemos

$$X' = X - a \quad \text{e} \quad Y' = Y - b, \quad \text{entonces} \quad S_{X'Y'} = S_{XY}$$

2. Si se hace un cambio de escala, esto es

$$X' = c \cdot X \quad \text{e} \quad Y' = d \cdot Y, \quad \text{entonces} \quad S_{X'Y'} = c \cdot d \cdot S_{XY}$$

3. De las propiedades anteriores se deduce que si hacemos

$$X' = \frac{X-a}{c} \quad \text{e} \quad Y' = \frac{Y-b}{d} \quad \text{entonces}$$

$$S_{X'Y'} = \frac{1}{c} \cdot \frac{1}{d} \cdot S_{XY} \quad \text{y} \quad S_{XY} = c \cdot d \cdot S_{X'Y'}$$

Las demostraciones son ejercicios fáciles.

4. Si X e Y son independientes, su covarianza es cero (el recíproco no es cierto, en general).

1.4.7 Coeficiente de correlación lineal

Se define como $r = \frac{S_{XY}}{S_X S_Y}$. Se utiliza para medir el grado de dependencia lineal entre las variables. El coeficiente de correlación lineal tiene las siguientes propiedades:

- $-1 \leq r \leq 1$
- $r^2 = 1$ sí y sólo si las observaciones se encuentran sobre una recta creciente o decreciente.
- Si X e Y son independientes entonces $r = 0$. (El recíproco no es cierto).



La relación lineal entre X e Y será mayor cuanto más próximo se encuentre r^2 a 1. Si $r = 0$, se dice que las variables son **incorreladas**, esto es, no existe relación lineal entre ambas.

Un valor positivo de r nos indica que existe dependencia directa entre las variables (a medida que aumentan los valores de X también aumentan los de Y) mientras que cuando $r < 0$, la dependencia es inversa (al aumentar los valores de X disminuyen los de Y).

